



Dropout = Apagar neuronas aleatoriamente

- * Alta tasa $\rightarrow$ ruleta rusa
- Mejora generalización por existir subredes neuronales
- * Las neuronas desactivadas no pasan nada ni hacia adelante ni hacia atrás
- **Computacionalmente económica**
- Reduce dependencia de neuronas
- * Se puede usar en CNN y capas totalmente conectadas
- * Aumenta el tiempo de entrenamiento
- * Demora más en converger
- * ~~Evita que la red aprenda valores más complejos~~
- * Colocar después de ReLU



Sin dropout



Con dropout

! No mezclar batch normalization con dropout!

Batch normalization

- * Normalizar entradas en cada mini batch

Ejemplo con una neurona

Batch 1
 $x = [1, 2, 3]$

Salidas
 $[0,5; 1; 1,5]$

Batch 2 (datos más grandes)

$x = [100, 200, 300]$

Salidas
 $[50; 100; 150]$

Pero normalizando μ σ^2

$y = [-1,22; 0; 1,22]$


$y = [-1,22; 0; 1,22]$

- ✓ Usar antes de funciones no lineales
- ✓ Usar por regla general
- ✓ Reduce los cambios en la distribución de las entradas de las capas
- ✓ Acelera el proceso de aprendizaje INTERNAL COVARIATE SHIFT
- ✓ Permite usar tasas de aprendizaje más altas
- * Rendimiento bajo en mini batches
- * Media y varianza pueden ser no representativos
- * No es adecuada para NLP


Técnicas de optimización

Optimizador { Algoritmo que
ajusta los pesos
de una red neuronal

Forward propagation $\Rightarrow$ Calculate loss



Modify weights $\Leftarrow$ Backpropagation



$$W_{\text{nuevo}} = W_{\text{viejo}} - \eta \frac{\partial L}{\partial W}$$

gradiente
Función de pérdida

① Descenso del gradiente

Tasa de aprendizaje

Parábola del excursionista

② SGD

Stochastic Gradient Descent

② SGD Stochastic Gradient Descent

Usa muestras aleatorias para calcular el descenso del gradiente

✓ Rápido

✗ Ruido

✓ Imágenes, entrenamiento largo y data set grande

✓ Cuando Adam sobreajusta

③ SGDM

Momentum { Velocidad acumulada de la pelota mientras baja

✓ Menos zig-zag ✗ Hipérparámetros

④ RMSprop

✓ RNN y LSTM

Semana 2

Funciones de pérdida


Son formas en que un modelo de aprendizaje automático mide que tan mal lo está haciendo. Comparan la predicción del modelo con el valor real y devuelven un número que representa el error.

Mean Squared Error

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

✓ Regresión

✓ Penaliza errores grandes



✗ Sensible a outliers
✗ No siempre refleja desempeño real.
✗ Comput. costoso

Cross-entropy

General = $-\sum_i p(x_i) \log q(x_i)$

Binaria = $-\left[y \log(p) + (1-y) \log(1-p)\right]$

Multiclase = $-\sum_{i=1}^n y_i \log(\hat{y}_i)$

Ejemplo: Un modelo predice prob(θ) para una observación cuya clase verdadera es A

	0,9	0,08	0,02
A	1	0	0

One Hot Encoding

$$L = -\left[1 \ln(0,9) + 0 \ln(0,08) + 0 \ln(0,02)\right] = 0,105$$

✓ Eficaz en clasificación

✓ Sensible a cambios

✓ Para múltiples clases

Hinge (bisagra)

✓ SVM o clasif. binaria

✓ Penaliza errores grandes

$L = \sum_{j \neq y} \max(0, 1 - (s_y - s_j))$

Ejemplo scores = [3, 2, 2, 0, 2, 5] A verdadera

$L = \max(0, 1 - (3 - 2)) + \max(0, 1 - (3 - 2,5))$

$L = \max(0, 1 - 1,2) + \max(0, 1 - 0,7)$

No pasó el margen $L = 0,3$ (Pasó el margen por eso hay error)

Kullback-Leibler $\int p \log \frac{p}{q}$ ✓ Cuantifica pérdida de información



✓ Diferencia de distribuciones de probabilidad de datos aprendidas y originales (discretas o continuas)

✓ Modelos generativos

✗ Medida asimétrica

Ejemplo: hay 80% cara, 20% sello. Modelo cree que hay 60% y 40%. Mientras más grande la diferencia, la distribución...

Forward propagation



Semana 3

Aprendizaje no supervisado clustering y autoencoders

Aprendizaje no supervisado $\Rightarrow$ Datos no etiquetados $\Rightarrow$ Descubrimiento de patrones


- Clustering o agrupamiento
- Reducción de dimensionalidad
- Detección de anomalías
- Extracción de características
- Reglas de asociación

L1 o Lasso

Partimos de

$$Z = X_1 w_1 + X_2 w_2 + \dots + X_n w_n$$

L1 empuja los pesos irrelevantes a 0, eliminando automáticamente variables que no contribuyen al modelo



λ es un hiperparámetro que controla que tan fuerte es la regularización

Imagina $\lambda = 10^{-4}$ $w_1 = -4$

$$\lambda/|w| = 10^{-4}/|-4| \approx 0$$

El gradiente lleva al peso a cero
 $\frac{\partial \lambda/|w|}{\partial w} = \text{sign}(w)$

$$\mathcal{L}(w) = \text{Error}(w) + \lambda/|w|$$

¿Conviene dejar w_1 si no aporta según λ ?

«Cada peso paga un costo por existir y si no vale la pena, desaparece»

✗ No funciona bien cuando hay multicolinealidad de características porque selecciona arbitrariamente

L2 o Ridge

Técnica de propósito general
Soluciona el problema de la colinealidad.

Es derivable en todos los puntos incluyendo cero.

$$\mathcal{L}(w) = \text{Error}(w) + \lambda \sum (w_i^2)$$

Ejemplo

$$\lambda = 0,1, w_1 = 3, w_2 = -4$$

$$\mathcal{L}(w) = \text{Error}(w) + 0,1(3^2 + (-4)^2)$$

✓ Rendimiento predictivo superior

Clustering: métricas de evaluación interna

Internas

① Inercia

$$\sum_{i=1}^n |x_i - c_i|^2$$

Qué tan cerca están los puntos de sus centroides


② Silhouette score

$$S = \frac{b-a}{\max(a,b)}$$

a: distancia promedio dentro del cluster
b: distancia promedio al cluster más cercano

Qué tan parecido es un punto a su propio cluster comparado con otros clusters

Autoencoder



Espacio original

Espacio latente

Cuello de botella = determina el grado de compresión

Espacio original = Espacio de entrada

Espacio de salida

Semana 4

Técnicas de regularización

Objetivo de la regularización

Classification



Regression



Delicado equilibrio entre el sobreajuste y la capacidad de generalización del modelo

Factores

Tamaño de los datos
Muchos datos → no regularizar
Pocos → + regularización

Complejidad del modelo
Modelos grandes, muchas capas → + R
Modelos simples → - R

Número de épocas
Muchas épocas → memoriz.

② Tarea ← Clasificar imágenes
Traducir idiomas
Detectar objetos

③ Tamaño del dataset

Estrategias

① Feature extraction

☐ Congelar 700
☐ No congelar 100
☒ Añadir capas

✓ Nuestro dataset pequeño
✓ Datasets similares
✓ Para nuevas clases o características

② Finetuning

☐ Congelar pocas
☒ Entrenar

✓ Nuestro dataset grande
✓ Cambio de dominio o tarea

Ejemplo: modelo preentrenado detecta gatos
quiero 10 tipos de gatos

Semana 10

Transfer learning: teacher student

⇒ Modelo grande enseña a uno pequeño o simple

Objetivo: que el student alcance un rendimiento menor similar o igual al del profesor, ~~menos~~ menos parámetros, memoria y mayor velocidad de inferencia.

↘ El student entrena para imitar las predicciones del teacher, además de (o en lugar de) las etiquetas reales

Knowledge distillation

Es la técnica con la que se implementa el TS.

$$L = \alpha L_{\text{hard}} + (1 - \alpha) L_{\text{distill}}$$

$$L = L_{\text{distill}}$$

$$L = \lambda_1 L_{\text{hard}} + \lambda_2 L_{\text{distill}} + \lambda_3 L_{\text{feature}}$$

Semana 9

Transfer learning:

Feature extraction and fine tuning

En vez de entrenar una red desde cero, tratar de aprovechar lo que otro modelo aprendió.

Problemas al entrenar un modelo de Deep Learning desde 0

① Cantidad de imágenes

* Recolección

* Captura

* Transformación

* Aumentación

② Recursos computacionales

③ Experiencia en hiperparám.

¿Cómo elegir el modelo?

① Dominio { Espacio en el que se encuentran los datos

Ejemplos

- Imágenes de un parque
- Radiografías
- Audio musical

Mientras más se parece el dominio, mejor.